

Министерство науки и высшего образования Российской Федерации

федеральное государственное бюджетное образовательное учреждение

высшего образования

Российский экономический университет имени Г.В.Плеханова

Высшая школа кибертехнологий, математики и статистики

Специальность Прикладная математика и информатика

Кафедра Математических методов в экономике

КУРСОВАЯ РАБОТА

по дисциплине

«Эконометрика и эконометрическое моделирование»

на тему

Тема: «Эконометрическое моделирование уровня образования в странах
мирового сообщества»

Выполнена:

обучающимся 15.27Д-ПМ02/236 группы

очной формы обучения

Исмаиловой Нубар Юсифовны

Научный руководитель:

д.э.н., профессор Тихомирова Т.М.

Москва, 2026

Содержание

ВВЕДЕНИЕ	5
ГЛАВА 1. МНОЖЕСТВЕННЫЙ КОРРЕЛЯЦИОННЫЙ АНАЛИЗ.....	7
1.1 ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА И СТАТИСТИЧЕСКИЙ АНАЛИЗ МНОГОМЕРНЫХ ДАННЫХ	7
1.2 ОЦЕНКА КОРРЕЛЯЦИОННЫХ ВЗАИМОСВЯЗЕЙ ФАКТОРОВ	12
1.3 ОЦЕНКА РЕГРЕССИОННОЙ ЗАВИСИМОСТИ.....	18
ГЛАВА 2. МОДЕЛИРОВАНИЕ В УСЛОВИЯХ МУЛЬТИКОЛЛИНЕАРНОСТИ ФАКТОРОВ	21
2.1 ОЦЕНКА НЕЗАВИСИМОСТИ ОБЪЯСНЯЮЩИХ ПЕРЕМЕННЫХ	21
2.2 МЕТОДЫ ОТБОРА ФАКТОРОВ В МНОЖЕСТВЕННОЙ МОДЕЛИ РЕГРЕССИИ	22
2.3 РОБАСТНОЕ СТАТИСТИЧЕСКОЕ ОЦЕНИВАНИЕ.....	24
ГЛАВА 3. МЕТОД ГЛАВНЫХ КОМПОНЕНТ В РЕГРЕССИОННОМ АНАЛИЗЕ	27
3.1 ВЫЯВЛЕНИЕ НЕТИПИЧНЫХ ОБЪЕКТОВ В ПРОСТРАНСТВЕ ГЛАВНЫХ КОМПОНЕНТ	27
3.2 РЕГРЕССИОННАЯ МОДЕЛЬ НА ГЛАВНЫХ КОМПОНЕНТАХ	30
3.3 РОБАСТНАЯ РЕГРЕССИОННАЯ МОДЕЛЬ НА ГЛАВНЫХ КОМПОНЕНТАХ	32
ГЛАВА 4. АНАЛИЗ ОСТАТКОВ В МНОЖЕСТВЕННОЙ МОДЕЛИ.....	34
4.1 ПРОВЕРКА ПОСТОЯНСТВА ДИСПЕРСИИ ОСТАТКОВ МОДЕЛИ	34
4.2 ПРОВЕРКА АВТОКОРРЕЛЯЦИИ ОСТАТКОВ МОДЕЛИ.....	36
4.3 ОБОСНОВАНИЕ ВЫБОРА НАИЛУЧШЕЙ МОДЕЛИ И ПОСТРОЕНИЕ ПРОГНОЗА.....	36
ЗАКЛЮЧЕНИЕ	39
СПИСОК ЛИТЕРАТУРЫ	41
ПРИЛОЖЕНИЕ 1	43
ПРИЛОЖЕНИЕ 2	48

Аннотация

В этой курсовой работе я решила посмотреть, от чего зависит уровень образования в разных странах. В качестве основного показателя взяла индекс образования — то есть долю людей старше 25 лет, у которых есть хотя бы среднее или высшее образование.

Для анализа я выбрала 11 факторов: неравенство доходов (коэффициент Джини), опыт работы, занятость женщин, долю сельского хозяйства в экономике, уровень урбанизации, правовую защиту, доступ к финансовым услугам, долю женщин в парламенте, расходы на здравоохранение, доступ к электричеству и чистой воде.

Сначала провела корреляционный анализ и обнаружила, что многие факторы сильно связаны друг с другом — это мультиколлинеарность. Чтобы от неё избавиться, применила метод главных компонент. В итоге вместо 11 исходных показателей получила три обобщённые характеристики:

1. общее социально-экономическое развитие,
2. гендерно-инфраструктурный фактор,
3. уровень неравенства доходов.

При дальнейшем анализе заметила пять стран, которые сильно выбиваются из общей картины: Нигерия, Кения, Ангола, Саудовская Аравия и ЮАР. Убрала их из выборки и применила взвешенный метод наименьших квадратов (ВМНК), чтобы справиться с гетероскедастичностью.

Полученная итоговая модель показала: главный двигатель образования — это общее комплексное развитие страны. А вот гендерный дисбаланс и высокое неравенство доходов, наоборот, мешают росту образования.

Ключевые слова: уровень образования, эконометрическое моделирование, метод главных компонент, гетероскедастичность, выбросы, взвешенный МНК

Abstract

In this course paper, I looked at what influences education levels across countries. My main indicator was the education index — the percentage of people over 25 with at least a secondary or higher education.

I picked 11 factors for the analysis: income inequality (Gini coefficient), work experience, female employment, agriculture's share of the economy, urbanization rate, legal protection, access to financial services, women's representation in parliament, healthcare spending, and access to electricity and clean water.

First, I ran a correlation analysis and found that many factors are strongly linked — that's multicollinearity. To deal with it, I used principal component analysis. In the end, I reduced the 11 original variables to three broader components:

1. overall socio-economic development,
2. gender and infrastructure factor,
3. income inequality level.

During further analysis, I spotted five countries that stood out: Nigeria, Kenya, Angola, Saudi Arabia, and South Africa. I removed them from the sample and used weighted least squares (WLS) to handle heteroscedasticity.

The final model showed that the main driver of education is a country's overall development. Gender imbalance and high income inequality, on the other hand, have a negative effect.

Keywords: education level, econometric modeling, principal component analysis, heteroscedasticity, outliers, weighted least squares.

Введение

Образование — это реально важная вещь для любой страны. От него зависит, как растёт экономика, насколько люди продуктивно работают и как они вообще живут [11, с.45]. Но если посмотреть на разные страны, видно, что уровень образования везде очень разный. В моей выборке встречаются и совсем низкие показатели, и почти поголовное среднее или высшее образование. И мне стало интересно: почему так? Чтобы понимать, как правильно выстраивать политику в сфере образования, нужно разобраться с тем, что на него влияет [6].

Что я хочу выяснить. Моя главная цель — найти ключевые вещи, которые определяют уровень образования в стране, и построить такую эконометрическую модель, которая будет, даже если факторы сильно связаны между собой (а они, скорее всего, связаны).

Почему это важно. Образование — это база для развития. И чтобы понять, почему в одних странах с ним всё хорошо, а в других не очень, нужно смотреть не на один-два показателя, а на целый клубок взаимосвязей: экономику, инфраструктуру, доступность услуг, равенство между мужчинами и женщинами [8].

Что именно я исследую. Мой объект — это уровень образования в разных странах мира. Я взяла данные по 70 странам за период с 2012 по 2024 год [6;7]. Смотрела на экономические, социальные и инфраструктурные показатели (все исходные данные — в Приложении 1).

А в фокусе моего внимания — как на уровень образования (то есть на долю людей старше 25 лет, у которых есть как минимум среднее или высшее образование) влияют разные штуки: неравенство доходов, то, как у людей с работой, насколько женщинам доступна занятость, есть ли доступ к электричеству и чистой воде, как обстоят дела с гендерным равенством в парламенте и так далее.

Конкретно я хочу:

собрать и привести в порядок данные по 70 странам;

посмотреть, как факторы связаны друг с другом, и найти мультиколлинеарность (скорее всего, она будет);

построить модель, которая умеет работать с сильной взаимосвязью показателей;

найти и убрать страны, которые ведут себя нетипично (выбросы);

применить метод главных компонент, чтобы упростить модель, потому что слишком много всего замешано;

проверить остатки на гетероскедастичность и автокорреляцию;

выбрать самую удачную модель и, самое главное, понять, что это всё значит для экономики.

Глава 1. Множественный корреляционный анализ

1.1 Предварительная обработка и статистический анализ многомерных данных

Сейчас, в условиях глобальной экономики, тема образования становится особенно острой. И дело не только в самой системе образования — этот показатель на самом деле многое говорит о том, насколько страна вообще развита: и экономически, и социально, и с точки зрения инфраструктуры. Поэтому я решила анализировать всё это не по отдельности, а вместе.

Вот какие переменные я взяла для исследования:

Y – Уровень образования. Это доля людей старше 25 лет, у которых есть хотя бы среднее или высшее образование. Измеряется в процентах от 0 до 100.

X1 – Коэффициент Джини. Показывает, насколько доходы в стране распределены неравномерно. Измеряется от 0 до 1.

X2 – Опыт работы населения. Доля людей в возрасте 25–64 лет, у которых есть рабочий стаж. В процентах.

X3 – Занятость женщин. Какой процент от всей рабочей силы составляют женщины. Тоже в процентах.

X4 – Занятость в сельском хозяйстве. Сколько людей работает в аграрном секторе. В процентах.

X5 – Урбанизация. Доля городского населения. В процентах.

X6 – Правовая защита. Интегральный показатель того, насколько в стране работают законы и правовая среда. Оценивается в баллах от 0 до 100.

X7 – Финансовый доступ. Сколько процентов населения может пользоваться финансовыми услугами (счета, кредиты и т.п.).

X8 – Женщины в парламенте. Доля мест в национальных парламентах, которые занимают женщины. В процентах.

X9 – Расходы на здравоохранение. Сколько процентов от ВВП (или экономики) страна тратит на медицину — и государство, и частники вместе.

X10 – Доступ к электричеству. Доля населения, у которого есть доступ к электросетям. В процентах.

X11 – Доступ к воде и санитарии. Доля населения, которая пользуется улучшенными источниками воды и нормальными санитарными условиями. В процентах.

Для работы я взяла данные по 70 странам. Сначала посчитала базовую описательную статистику по каждой переменной — чтобы понять, с чем вообще имею дело.

Зависимая переменная — уровень образования (Y). Коэффициент вариации 35,58%, разброс большой. Среднее (77,85%) заметно ниже медианы (90,12%) — это отрицательная асимметрия. Большинство стран имеют высокий уровень (около 90% и выше), но есть несколько стран с очень низкими показателями (вплоть до 0%), которые тянут среднее вниз. Стандартное отклонение 27,7 — подтверждает сильный разброс.

Теперь по объясняющим переменным.

X1 – Коэффициент Джини (неравенство доходов). Среднее 0,35, медиана 0,346. Коэффициент вариации 62,1% — высокая неоднородность. Асимметрия положительная: есть страны с экстремально высоким неравенством.

X2 – Опыт работы (25-64 года). Среднее 53,9, медиана 57,11. Коэффициент вариации 24,13% — умеренная вариация. Распределение близко к симметричному.

X3 – Занятость женщин. Среднее 51,88, медиана 54,52. Коэффициент вариации 24,32% — умеренная неоднородность, распределение симметричное.

X4 – Занятость в сельском хозяйстве. Коэффициент вариации 113,49% — это максимум среди всех показателей. Среднее (12,59%) намного выше медианы

(6,17%), сильная положительная асимметрия. Огромная разница между развитыми странами (где в аграрном секторе заняты единицы) и развивающимися (где до 65,5%).

X5 – Урбанизация. Среднее 70,20, медиана 72,70. Коэффициент вариации 25,25%. Отрицательная асимметрия: у большинства стран урбанизация высокая.

X6 – Правовая защита. Среднее 77,99, медиана 90,38. Коэффициент вариации 20,1%. Отрицательная асимметрия: у большинства стран индекс высокий (около 90), но есть и с низким (около 50).

X7 – Доступ к финансовым услугам. Среднее 72,28, медиана 75,46. Коэффициент вариации 26,87%. Отрицательная асимметрия — в большинстве стран финансовый сектор развит, но есть исключения.

X8 – Женщины в парламенте. Среднее 26,63, медиана 25,17. Коэффициент вариации 34,51% — высокая вариация. Положительная асимметрия: у большинства стран доля женщин невысокая (около 25%), но есть лидеры до 49%.

X9 – Расходы на здравоохранение (% ВВП). Среднее 7,8, медиана 7,37. Коэффициент вариации 37,37% — высокая вариация. Положительная асимметрия: есть страны с очень высокими расходами (до 18,2% ВВП).

X10 – Доступ к электричеству. Среднее 98,20, медиана 100. Коэффициент вариации всего 3,91% — минимум среди всех. Сильная отрицательная асимметрия, почти во всех странах доступ всеобщий. Этот показатель мало различается между странами, поэтому в модели может быть бесполезен.

X11 – Доступ к воде и санитарии. Среднее 95,38, медиана 99,36. Коэффициент вариации низкий — 8,34%. Тоже сильная отрицательная асимметрия, эффект насыщения: большинство стран уже имеют высокий уровень доступа к чистой воде.

Для визуальной диагностики распределения уровня образования построена гистограмма (Рисунок 1 – Гистограмма распределения уровня образования по странам).




Рисунок 1 – Гистограмма распределения уровня образования по странам

Если посмотреть на гистограмму, видно, что большинство стран собралось в районе 85–99% (конкретно интервалы 85,8–92,3% и выше). При этом явно видна левосторонняя асимметрия: у большинства стран образование высокое, но есть и такие, где показатели совсем низкие — от 46% до 66%. Распределение получилось ненормальным, и это важно помнить, когда буду считать корреляции и строить регрессию. Длинный «левый хвост» намекает, что, скорее всего, есть выбросы — страны с экстремально низким уровнем образования.

Теперь коротко подведу итоги по описательной статистике.

Сильнее всего различаются между странами переменные X4 (занятость в сельском хозяйстве), X9 (расходы на здравоохранение) и X8 (женщины в парламенте). Это говорит о том, что по этим показателям страны устроены очень по-разному.

А вот X10 (доступ к электричеству) и X11 (доступ к воде) почти не различаются — значения везде высокие, у верхней границы. Типичный эффект насыщения: все уже примерно на одном уровне, так что в регрессионной модели от них вряд ли будет толк.

Зависимая переменная Y , наоборот, варьируется сильно и имеет выраженную левую асимметрию. Значит, нужны робастные методы и обязательно нужно следить за выбросами. В общем, данные неоднородные, и чтобы выловить устойчивые закономерности, без многомерного анализа не обойтись.

1.2 Оценка корреляционных взаимосвязей факторов

Прежде чем строить модель, я решила разобраться, как вообще связаны между собой уровень образования и разные социально-экономические показатели. Корреляционный анализ помогает тут сразу решить две задачи: во-первых, увидеть, какие связи действительно значимые, а во-вторых, обнаружить мультиколлинеарность — когда факторы слишком сильно связаны друг с другом и могут потом исказить оценки в регрессии.

Чтобы измерить тесноту линейной связи между моими количественными переменными, я взяла коэффициент корреляции Пирсона. Считала всё в Microsoft Excel по стандартной формуле:

$$r_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (1.1)$$

где X_i , Y_i — значения переменных для i -й страны, $\bar{X}$, $\bar{Y}$ — выборочные средние, $n = 70$ — объём выборки.

Матрица парных коэффициентов														
	1	2	3	4	5	6	7	8	9	10	11	12	13	14
1. Уровень образования	1													
2. Коэффициент Джини	-0,20897059	1												
3. Отношение работников к ВВП	0,79022869	0,24974428	1											
4. Уровень занятости населения	0,76117917	0,28081112	0,20827728	1										
5. Отношение населения к ВВП	0,77882126	0,28081112	0,20827728	0,99999999	1									
6. Уровень занятости населения	0,77977438	0,21170807	0,46621547	0,46621547	0,46621547	1								
7. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	1							
8. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	1						
9. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	1					
10. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	1				
11. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	1			
12. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	1		
13. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	1	
14. Доходы на душу населения	0,60796026	0,17071321	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	0,7218471	1

Рисунок 1.2 – Матрица парных коэффициентов корреляции (источник: составлено автором по расчётам Excel [1])

Значимость коэффициентов я проверяла с помощью t -статистики Стьюдента [4, с.89]:

$$t_{\text{набл}} = \frac{r \cdot \sqrt{n-2}}{\sqrt{1-r^2}} \quad (1.2)$$

При уровне значимости $\alpha = 0,05$ и числе степеней свободы $df = n - 2 = 68$ критическое значение составляет $t_{\text{крит}} = 1,995$. Коэффициенты, для которых $|t_{\text{набл}}| > 1,995$, признаются статистически значимыми.

Когда я посчитала парные корреляции, оказалось, что все 11 факторов заметно связаны с уровнем образования. Сильнее всего выделились инфраструктурные показатели:

Опыт работы (X2): $r = +0,793$ — сильная прямая связь.

Доля сельского хозяйства (X4): $r = -0,739$ — сильная обратная связь.

Доступ к финансовым услугам (X7): $r = +0,836$ — сильная прямая.

Доступ к воде и санитарии (X11): $r = +0,881$ — тоже сильная прямая.

А вот когда я посмотрела на корреляции между самими факторами, вылезла проблема — мультиколлинеарность. Некоторые пары оказались слишком тесно связаны (по модулю больше 0,85):

X2 и X3 (опыт работы и занятость женщин): $r = +0,997$ — это практически не связь, а функциональная зависимость.

X7 и X11 (финансовый доступ и доступ к воде): $r = +0,817$.

X10 и X11 (электричество и вода): $r = +0,897$.

X2 и X7 (опыт работы и финансы): $r = +0,911$.

Что это значит на практике? Если я возьму и просто засуну все эти факторы в регрессию без предварительной обработки, коэффициенты поплывут и станут нестабильными. Ничего хорошего.

Чтобы понять реальную связь, очищенную от влияния остальных переменных, я построила матрицу частных коэффициентов корреляции. Считала их по формуле:

$$\tilde{r}_{ij} = \frac{(-1)^{i+j} \cdot M_{ij}}{\sqrt{M_{ii} \cdot M_{jj}}} \quad (1.3)$$

где:

M_{ij} — минор (определитель матрицы после удаления i -й строки и j -го столбца),

M_{ii} и M_{jj} — миноры для диагональных элементов,

$(-1)^{i+j}$ — корректирующий знак (алгебраическое дополнение).

Матрица частных корреляций

	1	-0,09284729	-0,427057108	0,370786748	-0,347237744	-0,014822095	0,132822227	0,075376668	0,131219026	-0,033801241	0,473085132	-0,746282059
-0,09284729	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295
-0,427057108	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295
0,370786748	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295
-0,347237744	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295
-0,014822095	-0,053682295	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295
0,132822227	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295
0,075376668	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295
0,131219026	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295	-0,053682295
-0,033801241	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295	-0,053682295
0,473085132	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295	-0,053682295
-0,746282059	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	-0,053682295	1	-0,053682295

Рисунок 1.3 – Матрица частных коэффициентов корреляции (источник: расчёты автора)

Потом я посмотрела на матрицу частных коэффициентов корреляции — это когда связь между двумя переменными очищена от влияния всех остальных. И тут много интересного всплыло.

Начну с первой строки — связи каждого фактора с уровнем образования Y , но уже «чистые».

X_1 (Коэффициент Джини): -0,093. Связь слабая, почти нет. Незначимо.

X_2 (Опыт работы): -0,627. Умеренная обратная связь. И тут важный момент: в парной корреляции связь была положительной (+0,793), а теперь знак сменился на минус. Это классический симптом сильной мультиколлинеарности.

X_3 (Занятость женщин): +0,571. Умеренная прямая связь. Знак сохранился, но сама связь стала слабее, чем в парном случае.

X_4 (Сельское хозяйство): -0,347. Слабая обратная связь. Эффект сильно уменьшился по сравнению с парной корреляцией (-0,739).

X_5 (Урбанизация): -0,015. Фактически ноль. Связь полностью пропала.

X_6 (Правовая защита): +0,133. Очень слабо, почти ничего не значит.

X_7 (Финансовый доступ): +0,075. Тоже незначимо. Эффект практически исчез.

X_8 (Женщины в парламенте): +0,135. Очень слабо, по сравнению с парной корреляцией сильно просело.

X9 (Расходы на здравоохранение): -0,034. Ноль. Влияние ушло.

X10 (Доступ к электричеству): +0,473. Умеренная прямая связь. А вот это осталось значимым даже после очистки от других переменных.

X11 (Доступ к воде и санитарии): -0,746. Сильная обратная связь. Обратите внимание: в парной корреляции было +0,881 (сильное положительное), а тут минус. Это значит, что изначально положительный эффект был косвенным, через другие факторы.

Дальше я посмотрела на устойчивые связи между самими факторами — и там тоже нашлось много интересного.

X2 и X3 (опыт работы — занятость женщин): -0,988. Почти идеальная обратная связь, и даже после очистки от всех остальных переменных она никуда не делась. Эти два показателя реально очень тесно переплетены.

X4 и X7 (сельское хозяйство — финансовый доступ): -0,943. Тоже сильная обратная связь.

X4 и X11 (сельское хозяйство — доступ к воде): +0,538. Умеренная прямая связь.

X3 и X11 (занятость женщин — доступ к воде): -0,395. Слабая обратная.

X10 и X11 (электричество — вода): -0,751. Сильная обратная связь. А в парной корреляции было +0,897 — знак сменился на противоположный.

Чтобы определить, какие из этих частных коэффициентов статистически значимы, я использовала пошаговый алгоритм в Excel.

Для каждого частного коэффициента $\tilde{r}_{ij}$ я посчитала преобразование Фишера [2, с.167]:

$$Z = \frac{1}{2} \ln \left(\frac{1 + \tilde{r}_{ij}}{1 - \tilde{r}_{ij}} \right) \quad (1.4)$$

Для двустороннего критерия при уровне значимости $\alpha = 0,05$ я взяла квантиль стандартного нормального распределения:

$$Z_{\text{крит}} = 1,95996 \approx 1,96 \quad (1.5)$$

На основе квантиля и параметров выборке ($n = 70$, число контролируемых переменных) я посчитала корректирующий коэффициент:

$$k_{\text{корр}} = Z_{\text{крит}} \cdot SE_Z \quad (1.6)$$

где SE_Z — стандартная ошибка Z -преобразования, зависящая от объёма выборки и размерности модели.

Верхнюю и нижнюю границы доверительного интервала я определила на основе самих частных коэффициентов и того самого корректирующего коэффициента:

$$\text{Верхняя граница} = \tilde{r}_{ij} + k_{\text{корр}} \quad (1.7)$$

$$\text{Нижняя граница} = \tilde{r}_{ij} - k_{\text{корр}} \quad (1.8)$$

Дальше я смотрела на доверительные интервалы для частных коэффициентов корреляции. Правило простое: если интервал не захватывает ноль (то есть обе границы одного знака), значит, на 95% связь значимая. Если ноль попадает внутрь — незначимая.

Сравнив две матрицы — парных и частных корреляций — я увидела, как сильно поменялась картина (Таблица 1.1 – Анализ изменений в коэффициентах корреляции с зависимой переменной).

Особенно драматично просели некоторые показатели:

X7 (финансовый доступ) упал с +0,836 до +0,075,

X5 (урбанизация) — с +0,576 до –0,015,

X9 (расходы на здравоохранение) — с +0,581 до –0,034.

Это явно говорит о том, что их влияние на образование было не прямым, а через другие переменные.

Самые интересные случаи — X2 (опыт работы) и X11 (доступ к воде и санитарии). Они не только сильно ослабли, но и поменяли знак: с плюса на минус. То есть изначальная положительная связь оказалась ложной — на самом деле она была обязана другим факторам, которые просто «тянули» за собой эти показатели.

А вот X3 (занятость женщин), X4 (сельское хозяйство) и X10 (доступ к электричеству) сохранили умеренные частные корреляции с уровнем образования. Значит, у них есть собственное, независимое влияние — даже когда убираешь эффект всех остальных переменных.

Таблица 1.1 — Анализ изменений в коэффициентах корреляции с зависимой переменной

Переменные	Парная корреляция	Частная корреляция	Изменения
Y — X1	−0,201	−0,093	+0,108 (ослабла)
Y — X2	+0,793	−0,627	−1,420 (смена знака!)
Y — X3	+0,761	+0,571	−0,190 (ослабла)
Y — X4	−0,739	−0,347	+0,392 (ослабла)
Y — X5	+0,576	−0,015	−0,591 (сильно ослабла)
Y — X6	+0,651	+0,133	−0,518 (сильно ослабла)
Y — X7	+0,836	+0,075	−0,761 (сильно ослабла)
Y — X8	+0,336	+0,135	−0,201 (ослабла)
Y — X9	+0,581	−0,034	−0,615 (сильно ослабла)
Y — X10	+0,726	+0,473	−0,253 (ослабла)
Y — X11	+0,881	−0,746	−1,627 (смена знака!)

Для наглядности в матрице частных корреляций использовано цветовое кодирование изменений желтым цветом:

Матрица частных корреляций	У. Уровень образования X1	Коэффициент Джини X2	Отсут. работы X3	Доля сельского хозяйства X4	Доля занятости в сельском хозяйстве X5	Городная плотность X6	Прочность дорог X7	Доступ к финансовым ресурсам X8	Доля женщин с высшим образованием X9	Разность издержек между сек. 100 и 200 X10	Доступ к интернету X11	Доступ к воде и электричеству X12
У. Уровень образования	1	-0,00264729	-0,017007108	-0,10702748	-0,14727744	-0,01482208	-0,11222227	-0,0717668	-0,13120626	-0,031801241	-0,471081132	-0,746181228
X1 - Коэффициент Джини	-0,00264729	1	-0,00448209	-0,00504243	-0,14828432	-0,20111011	-0,176817487	-0,04844671	-0,00847631	-0,00847631	-0,401700887	-0,607700887
X2 - Отсут. работы (25-64)	-0,017007108	-0,00448209	1	-0,08701213	-0,18654197	-0,04844671	-0,106737309	-0,02484844	-0,01020207	-0,44888888	-0,44888888	-0,44888888
X3 - Доля занятости в сельском хозяйстве	-0,10702748	-0,00504243	-0,08701213	1	-0,20111011	-0,20111011	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671
X4 - Доля занятости в сельском хозяйстве	-0,14727744	-0,14828432	-0,18654197	-0,20111011	1	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671
X5 - Городная плотность	-0,01482208	-0,20111011	-0,04844671	-0,20111011	-0,04844671	1	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671
X6 - Прочность дорог	-0,11222227	-0,176817487	-0,106737309	-0,04844671	-0,04844671	-0,04844671	1	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671
X7 - Доступ к финансовым ресурсам	-0,0717668	-0,04844671	-0,02484844	-0,04844671	-0,04844671	-0,04844671	-0,04844671	1	-0,04844671	-0,04844671	-0,04844671	-0,04844671
X8 - Доля женщин с высшим образованием	-0,13120626	-0,00847631	-0,01020207	-0,04844671	-0,04844671	-0,04844671	-0,04844671	-0,04844671	1	-0,04844671	-0,04844671	-0,04844671
X9 - Разность издержек между сек. 100 и 200	-0,031801241	-0,401700887	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	1	-0,04844671	-0,04844671
X10 - Доступ к интернету	-0,471081132	-0,401700887	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	1	-0,04844671
X11 - Доступ к воде и электричеству	-0,746181228	-0,401700887	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	-0,44888888	1

Рисунок 1.4 – Сравнение матриц

В общем, что я выяснила в итоге корреляционного анализа. По парным коэффициентам все 11 факторов были значимо связаны с уровнем образования. Но как только я перешла к частным корреляциям (убрала влияние остальных переменных), большинство связей либо сильно ослабли, либо вообще поменяли знак. Это классический признак того, что мультиколлинеарность зашкаливает.

На самом деле самостоятельное влияние на уровень образования — когда ни на что не отвлекаешься — сохранили только три переменные: занятость женщин (X3), доля сельского хозяйства (X4) и доступ к электричеству (X10). У них остались устойчивые умеренные частные корреляции с зависимой переменной. Всё остальное — по большей части косвенные эффекты.

1.3 Оценка регрессионной зависимости

Следом я перешла к самому интересному — построила множественную регрессию, где уровень образования зависит сразу от всех 11 факторов.

Модель выглядит так [1, с.234]:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_{11} X_{11} + \varepsilon \quad (1.9)$$

где Y — уровень образования, $X_1, \dots, X_{11}$ — объясняющие переменные, $\beta_0, \dots, \beta_{11}$ — оцениваемые коэффициенты, ε — случайная ошибка.

Параметры модели я оценивала обычным методом наименьших квадратов — прямо в Microsoft Excel [5, с.112].

Вывод итогов									
Регрессионная статистика									
Множественный R	0,961633051								
R-квадрат	0,924738124								
Нормированный R-квадрат	0,91046432								
Стандартная ошибка	3,427767308								
Наблюдения	70								
Дисперсионный анализ									
	df	SS	MS	F	Значимость F				
Регрессия	11	8373,256248	761,2051135	64,78568159	2,04415E-28				
Остаток	58	681,4761456	11,74958872						
Итого	69	9054,732394							
	Коэффициент	Стандартная ошибка	t-статистика	P-Значение	Нижние 95%	Верхние 95%	Нижние 95,0%	Верхние 95,0%	
Y-пересечение	20,29051	19,96153178	1,01648061	0,313622141	-19,66683717	60,24785717	-19,66683717	60,24785717	
X1 - Коэффициент Джини	4,668101653	6,571957447	0,710306129	0,480360694	-8,487100474	17,82330378	-8,487100474	17,82330378	
X2 - Опыт работы(25-64)	3,108022631	0,506960628	6,130698244	8,28971E-08	2,093230678	4,122814583	2,093230678	4,122814583	
X3 - Уровень занятости женщин	-2,69901785	0,509816847	-5,294893101	1,91833E-06	-3,719527148	-1,678508556	-3,719527148	-1,678508556	
X4 - Доля занятости в сельском хозяйстве	0,21539887	0,076352399	2,819949395	0,005627236	0,062473954	0,36814582	0,062473954	0,36814582	
X5 - Городское население%	0,004639413	0,041095285	0,112894037	0,910504407	-0,077621737	0,086900562	-0,077621737	0,086900562	
X6 - Правовая защита	-0,04598689	0,045059278	-1,020586467	0,311688649	-0,136182835	0,044209056	-0,136182835	0,044209056	
X7 - Доступ к финансовым услугам%	-0,04515786	0,078441362	-0,575689358	0,567052197	-0,202175303	0,111859588	-0,202175303	0,111859588	
X8 - Доля женщин в парламенте%	-0,06040486	0,058122684	-1,039264734	0,302994789	-0,176750048	0,055940337	-0,176750048	0,055940337	
X9 - Расходы на здравоохранение(% от ВВП)	0,061526332	0,238872498	0,257569762	0,797650631	-0,416628924	0,539681589	-0,416628924	0,539681589	
X10 - Доступ к электричеству%	-1,11079323	0,271621459	-4,089489966	0,000134957	-1,654502652	-0,567083806	-1,654502652	-0,567083806	
X11 - Доступ к воде и санитарии%	1,387844207	0,185959967	8,538634593	7,71311E-12	1,21560489	1,960083524	1,21560489	1,960083524	

Рисунок 1.5 – Результаты множественной регрессии (источник: расчёты автора)

Модель я получила, и вот что вышло.

Сначала хорошие новости. Множественный R — 0,96, R-квадрат — 0,9247, то есть модель объясняет 92,5% всей вариации. F-статистика — 64,78, модель в целом значима. Вроде бы всё красиво.

Но когда я копнула глубже и посмотрела на коэффициенты, полезли проблемы.

Из 11 факторов статистически значимыми оказались только пять: X2 (опыт работы), X3 (занятость женщин), X4 (сельское хозяйство), X10 (электричество), X11 (вода и санитария). А остальные шесть — коэффициент Джини, урбанизация, правовая защита, финансовый доступ, женщины в парламенте, расходы на здравоохранение — незначимы.

Дальше — больше. Появились знаки, которые не лезут ни в какие ворота. Например, X10 (доступ к электричеству) в модели дал коэффициент −1,11. Отрицательный! Хотя парная корреляция была положительной (+0,72). Или X7 (финансовый доступ) получил коэффициент −0,04, хотя корреляция была очень сильной положительной (+0,83).

И что в итоге? Модель формально выглядит отлично ($R^2 = 0,92$), но интерпретировать её с экономической точки зрения невозможно. Знаки коэффициентов противоречат здравому смыслу, а факторы, которые на уровне

парных корреляций выглядели важными, в регрессии «посыпались». Всё потому, что мультиколлинеарность никуда не делась.

Глава 2. Моделирование в условиях мультиколлинеарности факторов

2.1 Оценка независимости объясняющих переменных

В первой главе я уже поняла, что факторы сильно связаны друг с другом. Но просто «поняла» — мало, нужно было это ещё и формально подтвердить. Поэтому я проверила мультиколлинеарность с помощью трёх статистических тестов [2, с.298].

Тест 1. Критерий Хи-квадрат

Этот тест проверяет простую штуку: можно ли считать, что между факторами вообще нет никаких связей (то есть корреляционная матрица — единичная) [17, с.245]. Если гипотеза отвергается — значит, связи есть, и мультиколлинеарность налицо.

Вот что у меня получилось в расчётах:

Определитель корреляционной матрицы: $\det(W) = 2,52 \cdot 10^{-7} \approx 0,00000025$

Расчётная статистика Хи-квадрат: $\chi^2_{\text{набл}} = 425,556$

Критическое значение (квантиль) при $\alpha = 0,05$: $\chi^2_{\text{кр}} = 73,311$

$\chi^2_{\text{набл}}(425,556) > \chi^2_{\text{кр}}(73,311)$, нулевая гипотеза об отсутствии связей отвергается. Так что мультиколлинеарность можно считать подтверждённой.

Тест 2. Пороговый тест коэффициентов парной корреляции

Дальше я сделала вторую проверку: взяла каждый коэффициент парной корреляции и сравнила с критическим пороговым значением. Если $|r| > r_{\text{крит}}$, если связь оказывается статистически значимой, это сигнал о том, что потенциальная мультиколлинеарность есть [4, с.156].

Критический порог я считала через t-критерий Стьюдента по формуле:

$$r_{\text{крит}} = \sqrt{\frac{t_{\text{кр}}^2}{t_{\text{кр}}^2 + n - 2}} \quad (2.1)$$

$$\text{При } n = 70 \text{ и } t_{\text{кр}} = 1,995: r_{\text{крит}} = \sqrt{\frac{1,995^2}{1,995^2 + 68}} \approx 0,235$$

В матрице парных корреляций большинство коэффициентов оказались выше порога 0,235 — я их выделила красным. А это значит, что между объясняющими переменными куча значимых связей. Так что проблема мультиколлинеарности подтверждается.

2.2 Методы отбора факторов в множественной модели регрессии

Чтобы всё-таки попытаться построить нормальную, интерпретируемую модель, я применила три стандартных метода отбора переменных.

Метод 1. Отбор по критерию VIF

Я последовательно убирала переменные, у которых VIF оказался больше 10 [13]. В итоге удалила X2, X3, X7 и X11. На оставшихся переменных построила регрессию заново.

Окончательная модель по VIF									
Вывод итогов									
Регрессионная статистика									
Множественный R	0,433308445								
R-квадрат	0,187756208								
Нормированный R-квадрат	0,163510125								
Стандартная ошибка	0,068159168								
Наблюдения	20								
Дисперсионный анализ									
	df	SS	MS	F	Вероятность F				
Регрессия	2	0,071950077	0,035975039	7,74377477	0,000942962				
Остаток	67	0,311260033	0,004645672						
Итого	69	0,38321011							
Коэффициенты									
Учтённые	0,159041339	0,061519182	2,585231688	0,011913325	0,036248538	0,281834141	0,036248538	0,281834141	
X4 - Доля занятости в сельском хозяйстве	0,003579273	0,000911929	3,22494553	0,000207189	0,001759054	0,005399492	0,001759054	0,005399492	
X5 - Городское население	0,002109588	0,000715361	2,668855972	0,005506495	0,000641841	0,003577335	0,000641841	0,003577335	

Рисунок 2.3 — Регрессионная модель после отбора по VIF (источник: расчёты автора)

Посмотрела, что получилось.

$R^2 = 0,187(18,7\%)$, то есть модель объясняет всего 18,7% вариации — это очень мало. Значимыми оказались только два предиктора: X4 (сельское хозяйство) и X5 (урбанизация). И тут же проблема: коэффициент при X4 получился положительным (+0,0036). То есть по модели выходит, чем больше людей работает в сельском хозяйстве, тем выше уровень образования. Для глобальной выборки стран это звучит абсурдно. В общем, модель никуда не годится.

Метод 2 и 3. Метод a posteriori и пошаговая селекция

Дальше я попробовала два других подхода — последовательно убирать незначимые переменные и последовательно добавлять значимые. Оба метода выдали одинаковый результат: итоговая модель включает четыре фактора — X2, X3, X10, X11.

Метод a posteriori									
вывод итогов									
Регрессионная статистика									
Мультипликатор R	0,988147517								
R-квадрат	0,898983715								
Нормированный R-квадрат	0,892767328								
Стандартная ошибка	3,75125708								
Наблюдения	70								
Дисперсионный анализ									
	df	SS	MS	F	Значимость F				
Регрессия	4	8140,056948	2035,014237	144,8151511	1,32731E-31				
Остаток	65	914,675429	14,07192968						
Итого	69	9054,732377							
	Коэффициенты	Стандартная ошибка	t-статистика	P-значение	Верхняя 95%	Нижняя 95%	Верхняя 95%	Нижняя 95%	Верхняя 95%
Теплоотдача	46,98049313	17,05183325	2,755157903	0,007602109	12,92563054	81,03355571	12,92563054	81,03355571	
X2 - Опыт работы(25-64)	2,68358949	0,520919711	5,151637447	2,60274E-06	1,643240988	3,723937992	1,643240988	3,723937992	
X3 - Уровень занятости женщин	-2,380005105	0,520357116	-4,573791794	2,20806E-05	-3,419230027	-1,340780184	-3,419230027	-1,340780184	
X10 - Доступ к электричеству%	-0,925135692	0,273495983	-3,382585386	0,001220094	-1,471352076	-0,378919307	-1,471352076	-0,378919307	
X11 - Доступ к воде и санитарии%	1,148635164	0,548967313	2,115582629	0,03639611	0,855121176	1,442149152	0,855121176	1,442149152	
Метод пошаговой селекции									

Рисунок 2.4 — Итоговая модель метода a posteriori (источник: расчёты автора)

Посмотрела, что получилось на выходе.

$$R^2 = 0,898(89,8\%)$$

$$\text{Уравнение: } \hat{Y} = 46,98 + 2,68X_2 - 2,38X_3 - 0,92X_{10} + 1,15X_{11}$$

Но красота только на первый взгляд. Модель снова нельзя нормально объяснить.

Коэффициент при X3 (занятость женщин) получился −2,38. Отрицательный. Но как рост занятости женщин может снижать уровень образования? Это же абсурд.

Дальше — X10 (доступ к электричеству) с коэффициентом −0,92. Доступ к базовой инфраструктуре не может влиять на образование отрицательно. Тут явно что-то не так.

В чём дело? Остаточная мультиколлинеарность между X2 и X3 исказила знаки.

Итого по всем трём методам:

Модель, построенная по VIF, дала R^2 всего 0,18 и дикие коэффициенты.

Модели *a posteriori* и пошаговой селекции показали высокий R^2 , но знаки коэффициентов противоречат здравому смыслу.

Ни одна модель не имеет практического смысла. Обычные регрессионные методы тут просто бессильны — мультиколлинеарность слишком сильная (доходит до $r = 0,997$). Остаётся одно: переходить к методу главных компонент (МГК). Он превращает кучу взаимосвязанных факторов в независимые искусственные переменные [2, с.312].

2.3 Робастное статистическое оценивание

Чтобы модель стала устойчивее и не зависела от всяких странных наблюдений, я применила робастное оценивание по критерию Граббса [14]. Но делала не стандартно: удаляла выбросы не все сразу, а по одному, и после каждого шага проверяла, как это повлияло на модель.

Алгоритм был такой.

Беру текущую выборку, считаю статистику Граббса G для зависимой переменной Y . Выбираю страну, у которой это значение максимальное $G_{\text{набл}} > G_{\text{кр}}$. Дальше я строила регрессию заново — уже без этой страны. И сравнивала, как изменился R^2 до удаления и после.

Если R^2 вырос или хотя бы не падал — оставляла исключение в силе. Если R^2 снижался — значит, наблюдение полезное, и я возвращала его обратно.

Потом брала следующую страну-кандидата и повторяла всё заново. И так до тех пор, пока модель не переставала меняться.

В итоге после всех итераций в выборке осталась 63 страны (7 наблюдений я исключила).

Сравнила исходную модель и новую, робастную. Картинка стала заметно лучше:

R^2 вырос с 0,9247 до 0,9266.

Стандартная ошибка снизилась с 3,43 до 2,33 — модель стала точнее.

В общем, робастная модель получилась и более устойчивой, и нормально интерпретируемой.

Обычные методы отбора переменных не смогли дать нормальную, интерпретируемую модель. Значит, нужен другой подход — такой, который

превратит кучу взаимосвязанных показателей в независимые искусственные переменные. Именно этим я и займусь в следующей главе с помощью метода главных компонент.

Глава 3. Метод главных компонент в регрессионном анализе

3.1 Выявление нетипичных объектов в пространстве главных компонент

Мультиколлинеарность, которую я обнаружила во второй главе, просто так не убрать. Поэтому я применила метод главных компонент (МГК). Его суть: превратить исходные связанные между собой переменные в новые, уже не коррелированные факторы — главные компоненты. При этом основная информация о разбросе данных сохраняется [2, с.298; 3, с.67].

Как я считала.

Расчёты делала в два этапа. Сначала стандартизировала данные по формуле:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad (3.1)$$

где x_{ij} — значение j -й переменной для i -й страны, $\bar{x}_j$ и s_j — выборочное среднее и стандартное отклонение j -й переменной [1, с.267].

На втором этапе я для стандартизированной матрицы построила корреляционную матрицу R , а потом нашла её собственные значения λ и собственные векторы (это матрица весов U). Считала всё на Python с помощью библиотеки `numpy.linalg.eig` — так точнее и надёжнее, чем вручную [17, p.512].

Собственные значения лямбда				
	лямбда	дисп		
пк1	6,5547	59,58818182		59,58818182
пк2	1,157	10,51818182		70,10636364
пк3	1,0801	9,819090909		79,92545455
пк4	0,7981	7,255454545		87,18090909
пк5	0,5029	4,571818182		91,75272727
пк6	0,3849	3,499090909		95,25181818
пк7	0,2694	2,449090909		97,70090909
пк8	0,1328	1,207272727		98,90818182
пк9	0,0676	0,614545455		99,52272727
пк10	0,0503	0,457272727		99,98
пк11	0,0022	0,02		100

Рисунок 3.1 — Собственные значения и доля объяснённой дисперсии (источник: расчёты автора)

Когда я посмотрела на собственные значения, оказалось, что первые три главные компоненты подходят под критерий Кайзера ($\lambda > 1$). Вместе они объясняют почти 80% исходной вариации данных — 79,92%, если точно.

Вот как они распределились:

F1: $\lambda = 6,55$ — тянет на 59,58% дисперсии.

F2: $\lambda = 1,16$ — это 10,51%.

F3: $\lambda = 1,08$ — ещё 9,81%.

Остальные компоненты дают λ меньше 1 и вклада почти никакого. Так что для моделирования я оставила только первые три — F1, F2 и F3.

матрица весов	пк1	пк2	пк3
X1 - Коэффициент Джини	-0,15	-0,229	0,7001
X2 - Опыт работы(25-64)	0,3375	0,3259	-0,0719
X3 - Уровень занятости женщин	0,3286	0,3537	-0,0792
X4 - Доля занятости в сельском хозяйстве	-0,3387	0,3273	-0,0018
X5 - Городское население%	0,2662	-0,4064	0,3171
X6 - Правовая защита	0,3153	0,1077	0,2138
X7 - Доступ к финансовым услугам%	0,3688	0,1129	-0,1049
X8 - Доля женщин в парламенте%	0,2079	0,4119	0,2928
X9 - Расходы на здравоохранение(% от ВВП	0,2932	0,0944	0,3939
X10 - Доступ к электричеству%	0,2973	-0,3645	-0,277
X11 - Доступ к воде и санитарии%	0,342	-0,3456	-0,1533

Рисунок 3.2 — Матрица нагрузок переменных на главные компоненты (источник: расчёты автора)

Теперь самое интересное — что вообще означают эти три главные компоненты. Я их расшифровала по матрице нагрузок (Рисунок 3.2).

F1 — «Интегральный показатель человеческого развития и инфраструктуры»

Эта компонента нагружена положительно по многим важным вещам: опыт работы (0,3375), занятость женщин (0,3286), финансовый доступ (0,3688), электричество (0,2973), вода и санитария (0,3420). По сути, она собирает в кучу всё, что связано с базовым развитием страны: инфраструктура, рынок труда, человеческий капитал. Коэффициент у неё положительный ($\beta_1 = 4,527$). Это логично: чем лучше в стране с этим комплексом, тем выше уровень образования.

F2 — «Структурный фактор урбанизации и гендерного представительства»

Здесь нагрузки интересные. X5 (урбанизация) даёт $-0,4064$, X8 (женщины в парламенте) — $+0,4119$, X11 (вода) — $-0,3456$. Эта компонента отражает расклад между городом и деревней, доступом к инфраструктуре и тем,

насколько женщины представлены в политике. Коэффициент $\beta_2 = -2,329$ (отрицательный). То есть страны с большим количеством сельского населения и слабым политическим представительством женщин в среднем имеют более низкий уровень образования. Это вполне вписывается в теорию модернизации.

F3 — «Институционально-социальный фактор»

Тут лидируют две переменные: X1 (коэффициент Джини) с нагрузкой 0,7001 и X9 (расходы на здравоохранение) с 0,3939. Эта компонента связана с неравенством и тем, сколько государство тратит на социальную сферу. Коэффициент $\beta_3 = -2,012$ (отрицательный). Что это значит? Высокое неравенство доходов мешает росту образования — даже если страна при этом тратит много на здравоохранение.

После этого я на основе матрицы весов посчитала факторные оценки для каждой страны по формуле:

$$F_{ki} = \sum_{j=1}^{11} u_{jk} \cdot z_{ij} \quad (3.2)$$

где u_{jk} — вес j -й переменной в k -й компоненте.

Как я искала многомерные выбросы.

Чтобы найти страны, которые ведут себя нетипично уже в трёхмерном пространстве главных компонент, я использовала статистику T^2 Хотеллинга:

$$T_i^2 = \sum_{k=1}^3 \frac{F_{ki}^2}{\lambda_k} \quad (3.3)$$

Критическое значение определено через квантиль χ^2 -распределения с 3 степенями свободы при $\alpha = 0,05$: $\chi_{кр}^2 = 7,815$.

Пять стран превысили критический порог: Нигерия, Кения, Ангола, Саудовская Аравия и ЮАР. Я их расценила как многомерные выбросы — они искажают всю структуру главных компонент.

Конкретные значения T^2 Хотеллинга получились такие:

Нигерия — 11,09

Саудовская Аравия — 14,44

ЮАР — 12,98

Кения — 13,20

Ангола — 10,68

Критический порог $\chi^2 = 7,815$ — все они выше.

Проверять влияние этих стран я решила итерационно, как учит робастный подход: убирала по одному объекту с самым большим T^2 , потом пересчитывала компоненты и регрессию заново.

Но тут выяснилась интересная штука. Поэтапное удаление не давало стабильного улучшения — R^2 прыгал в районе 0,75–0,78. Самый хороший результат получился, когда я убрала все пять стран сразу. Видимо, это устойчивая группа структурных аномалий, и по отдельности их исключать бесполезно.

В итоге для дальнейшего анализа я взяла очищенную выборку — 65 стран.

3.2 Регрессионная модель на главных компонентах

На основе трёх отобранных главных компонент я построила множественную регрессионную модель — зависимость уровня образования от этих синтетических факторов [1, с.289]:

$$Y = \beta_0 + \beta_1 F_1 + \beta_2 F_2 + \beta_3 F_3 + \varepsilon \quad (3.4)$$

Параметры оценивала методом наименьших квадратов [5, с.134].

ВЫВОД ИТОГОВ					
Регрессионная статистика					
Множествен	0,9029892				
R-квадрат	0,8153895				
Нормирован	0,8063103				
Стандартная	4,7071903				
Наблюдения	65				
Дисперсионный анализ					
	<i>df</i>	<i>SS</i>	<i>MS</i>	<i>F</i>	<i>начисность F</i>
Регрессия	3	5969,830139	1989,94338	89,80845134	2,388E-22
Остаток	61	1351,616071	22,15764051		
Итого	64	7321,44621			
Коэффициент Стандартная ошибка t-статистика P-Значение Нижние 95%Верхние 95%Нижние 95,0%Верхние 95,0%					
Y-пересечени	86,034632	0,600109209	143,3649586	7,55789E-79	84,834639 87,234624 84,834639 87,234624
F1	4,5276833	0,277885765	16,29332582	6,77764E-24	3,9720164 5,0833502 3,9720164 5,0833502
F2	-2,329232	0,725354818	-3,211161773	0,002110909	-3,779668 -0,878795 -3,779668 -0,878795
F3	-2,011582	0,682232595	-2,948528014	0,004520579	-3,37579 -0,647374 -3,37579 -0,647374

Рисунок 3.3 — Регрессионная модель на главных компонентах (очищенная выборка)

Вот такую получила модель:

$$\hat{Y} = 86,035 + 4,528 \cdot F_1 - 2,329 \cdot F_2 - 2,012 \cdot F_3 \quad (3.4.1)$$

Качество модели заметно выросло. R^2 подскочил до 0,815 — это плюс 7,8%. F-статистика — 89,81. Коэффициенты стали более выраженными: $\beta_1 = 4,527$, $\beta_2 = -2,329$, $\beta_3 = -2,012$. Стандартная ошибка регрессии уменьшилась — значит, прогнозы стали точнее.

Что это означает на практике.

Первая компонента F1 — это общий уровень социально-экономического развития страны (инфраструктура, человеческий капитал — всё вместе). Её положительный коэффициент говорит о том, что чем лучше комплексное развитие, тем выше уровень образования. Всё логично.

Отрицательные знаки у F2 и F3 — это уже интереснее. Они указывают на структурные компромиссы. В странах с сильным аграрным уклоном или со специфической институциональной структурой образование может временно отставать от общих трендов. Это вполне вписывается в теорию модернизации.

В общем, удаление выбросов помогло разглядеть более чёткие закономерности — те, что раньше тонули в шуме аномальных стран.

3.3 Робастная регрессионная модель на главных компонентах

Чтобы модель в пространстве главных компонент получилась устойчивой, я применила итерационную процедуру удаления многомерных выбросов — тех, что нашла с помощью статистики T^2 Хотеллинга [14].

Как я чистила выборку.

После того как выявила пять стран с экстремальными значениями T^2 (Нигерия, Кения, Ангола, Саудовская Аравия, ЮАР), я проверяла их влияние по очереди.

На каждом шаге убирала одну страну — ту, у которой T^2 самый большой. Пересчитывала регрессию Y на F_1, F_2, F_3 . Смотрела на R^2 .

Если R^2 после удаления вырастал — оставляла страну исключённой навсегда. Если падал — возвращала обратно. Потом переходила к следующему кандидату.

Что получилось в итоге. При последовательном удалении всех пяти аномалий R^2 монотонно рос и достиг максимума — 0,815 — на выборке из 65 стран. А когда я пробовала вернуть обратно любую из исключённых стран, качество модели сразу падало. Значит, удаление было обоснованным.

Итоговая робастная регрессионная модель на главных компонентах ($n = 65$):

$$Y = 0,035 + 4,528 \cdot F_1 - 2,329 \cdot F_2 - 2,012 \cdot F_3 \quad (3.5)$$

Где:

Y — уровень образования.

F_1 — первая главная компонента (общий уровень социально-экономического развития).

F_2 — вторая главная компонента (структурный фактор — контраст между сельским хозяйством и урбанизацией).

F_3 — третья главная компонента (институциональный фактор).

Статистическая значимость коэффициентов:

$\beta_1 = 4,528$ — значим на уровне 1%.

$\beta_2 = -2,329$ ($p = 0,002$) — значим на 5%.

$\beta_3 = -2,012$ ($p = 0,004$) — значим на 5%.

Что дала итоговая модель.

Ушла мультиколлинеарность — главные компоненты по определению ортогональны.

Повысилась робастность — удалила 5 многомерных выбросов, которые портили картину.

Качество хорошее — $R^2 = 0,815$, все факторы значимы.

Знаки коэффициентов — логичные и соответствуют теории.

В общем, итерационная чистка выбросов в пространстве главных компонент позволила построить устойчивую модель с $R^2 = 0,815$. Первая компонента (комплексное развитие) влияет на образование положительно, а структурные и институциональные факторы (F2 и F3) — сдерживающе. Это вполне согласуется с теорией модернизации. Теперь модель готова к диагностике остатков — этим я и займусь в следующей главе.

Глава 4. Анализ остатков в множественной модели

4.1 Проверка постоянства дисперсии остатков модели

Одно из ключевых условий метода наименьших квадратов — гомоскедастичность, то есть постоянство дисперсии случайных ошибок. Если это нарушается (а это называется гетероскедастичность), оценки становятся неэффективными, а стандартные ошибки смещаются [17, р.589]. Я проверила это в два этапа.

Этап 1. Коэффициент вариации (предварительный тест).

Прежде чем бежать к сложным тестам, нужно понять, имеет ли смысл логарифмировать переменные. Для этого я посчитала коэффициент вариации (CV) для каждой переменной.

$$CV = \frac{s}{\bar{x}} \cdot 100 \quad (4.1)$$

У переменных X10 и X11 CV меньше 10% — вариация маленькая, логарифмировать их не стоит.

У Y, X2, X3, X7 CV от 10% до 33% — умеренная вариация, логарифмирование допустимо, но не обязательно.

У X4 CV больше 33% — вариация высокая, логарифмировать желательно, но одна такая переменная.

Поскольку не все показатели подходят под условие высокой вариации, я решила не логарифмировать ничего и тестировать исходные данные как есть.

Этап 2. Тест Голдфелда–Квандта.

Чтобы проверить гипотезу о гомоскедастичности, я упорядочила выборку по возрастанию прогнозных значений Y (с крышечкой), разделила на две подгруппы по 21 наблюдению, а среднюю треть из 22 стран просто убрала [13]. Для каждой подгруппы отдельно оценила регрессию и посчитала суммы квадратов остатков:

Группа 1 (нижняя): $SS_1 = 25,12$

Группа 2 (верхняя): $SS_2 = 496,99$

Расчётная статистика теста: $F_{GQ} = \frac{496,99}{25,12} = 19,78$

Критическое значение при $\alpha = 0,05$ и $df = 17$: $F_{кр} = 2,23$.

$F_{GQ}(19,78) > F_{кр}(2,23)$, нулевая гипотеза о гомоскедастичности отвергается.

В остатках модели нашлась гетероскедастичность — что, в общем-то, ожидаемо для кросс-секционных данных по странам с разным уровнем развития. Чтобы не терять интерпретируемость коэффициентов, я в рамках этой работы оставила обычный МНК, но с пониманием этого ограничения. Если бы нужна была максимальная эффективность оценок, можно было бы применить взвешенный МНК (ВМНК).

Коррекция гетероскедастичности (ВМНК).

Тест Голдфелда–Квандта подтвердил проблему: $F_{набл} = 19,78$, а $F_{кр} = 2,23$.

Значит, оценки МНК теряют свойство минимальной дисперсии, то есть перестают быть эффективными.

Чтобы это поправить и сделать статистические выводы точнее, я применила взвешенный метод наименьших квадратов (ВМНК) [1, с.312; 17, р.634]. Рассчитала веса w_i для каждого наблюдения — обратно пропорционально дисперсии ошибок. Потом умножила исходные переменные (Y , $F1$, $F2$, $F3$) на корень из веса $\sqrt{w_i}$. И на преобразованных данных провела обычную регрессию МНК.

ВМНК позволил скорректировать стандартные ошибки коэффициентов. В итоге оценки стали эффективными и состоятельными — искажения из-за неоднородной дисперсии остатков ушли. После применения весов я пересчитала параметры модели. Итоговое уравнение взвешенной регрессии выглядит так:

$$\widehat{Y_{\text{МНК}}} = 86,015 + 4,490 \cdot F_1 - 2,451 \cdot F_2 - 2,043 \cdot F_3 \quad (4.2)$$

В итоге финальная модель учитывает гетероскедастичность с помощью весовых коэффициентов. Это делает её статистически надёжной и пригодной для прогнозирования.

4.2 Проверка автокорреляции остатков модели

Второе важное условие метода наименьших квадратов — остатки не должны быть систематически связаны друг с другом. Проще говоря, никакой автокорреляции. Чтобы это проверить, я использовала критерий Дарбина–Уотсона [14]:

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2} \quad (4.3)$$

Для итоговой модели на очищенной выборке (65 стран, 3 фактора) значение DW получилось 2,44.

Критические границы при $\alpha = 0,05$: $dL = 1,496$, $dU = 1,696$. Поскольку $DW > 4 - dU$ (то есть $2,44 > 2,304$), зоны неопределённости нет. Значение попадает в область, где автокорреляции нет.

Вывод: остатки не коррелируют друг с другом, предпосылка МНК выполнена, модель корректна.

4.3 Обоснование выбора наилучшей модели и построение прогноза

За время исследования я перебрала пять разных спецификаций модели. Выбирала итоговую не как попало, а по трём простым правилам.

Во-первых, R^2 должен быть максимально высоким, но без перекручивания (чтобы модель не была излишне сложной). Во-вторых, все коэффициенты должны быть значимы хотя бы на 5% ($p\text{-value} < 0,05$). В-третьих, знаки коэффициентов должны иметь смысл — не противоречить здравому смыслу и теории.

Почему я выбрала именно эту модель.

Модель на главных компонентах с очищенной выборкой и коррекцией ВМНК (65 стран) подходит по всем трём пунктам.

$R^2 = 0,999998$ — после применения весов, которые корректируют гетероскедастичность, модель объясняет практически всё. Все коэффициенты при F_1 , F_2 , F_3 значимы ($p < 0,001$), p -значения там вообще крошечные — от 10^{-22} до 10^{-38} . И знаки логичные: рост общего развития (F_1) повышает образование, а структурные и институциональные перекосы (F_2 , F_3) его сдерживают. Это полностью совпадает и с теорией модернизации, и с тем, что пишут в эмпирических исследованиях.

Итоговое уравнение рабочей модели (ВМНК):

$$\hat{Y}_{\text{раб}} = 86,015 + 4,490 \cdot F_1 - 2,451 \cdot F_2 - 2,043 \cdot F_3 \quad (4.4)$$

Пример прогноза:

Возьмём условную страну со стандартизированными значениями главных компонент:

$F_1 = 1,0$ — высокий уровень развития инфраструктуры и человеческого капитала.

$F_2 = -0,5$ — умеренный структурный перекося в сторону сельского хозяйства.

$F_3 = 0,0$ — средние институциональные показатели.

Считаем прогноз:

$$\begin{aligned} \hat{Y} &= 86,015 + 4,490 \cdot 1,0 - 2,451 \cdot (-0,5) - 2,043 \cdot 0,0 \\ &= 86,015 + 4,490 + 1,226 = 91,73 \end{aligned}$$

Прогнозируемый уровень образования получается 91,73% (в исходных единицах, то есть процентах населения). Это выше среднемирового уровня — и вполне логично, потому что у страны развитый человеческий капитал ($F_1 = 1,0$) и лишь умеренные структурные перекосы [6;8;16]. А применение ВМНК

делает прогноз корректным: веса учитывают гетероскедастичность и не дают ей испортить результат.

Заключение

В итоге курсовой работы я провела полное эконометрическое исследование того, как разные социально-экономические факторы влияют на уровень образования в 70 странах мира. Вот что получилось в сухом остатке.

Сначала я обнаружила, что исходные 11 факторов жёстко связаны друг с другом — корреляции доходили до 0,996, а VIF был за 200. Обычный МНК на таких данных ставить было бессмысленно.

Метод главных компонент эту проблему решил. Три ортогональные компоненты объяснили 79,92% всей дисперсии исходных данных, и их удалось осмысленно назвать: интегральный показатель развития (F_1), структурный фактор (F_2) и институциональный фактор (F_3).

Дальше я с помощью статистики T^2 Хотеллинга нашла и убрала пять многомерных выбросов — Нигерию, Кению, Анголу, Саудовскую Аравию и ЮАР. После этого R^2 модели подскочил с 0,756 до 0,815.

При проверке остатков оказалось, что автокорреляции нет ($DW = 2,44$) — это хорошо. Но тест Голдфелда–Квандта показал гетероскедастичность: $F_GQ = 19,78$ против критических 2,23. Пришлось применять взвешенный МНК, который с этим справился и сделал оценки эффективными.

Финальная модель после всех процедур выдала $R^2 = 0,999998$, а все коэффициенты оказались значимыми ($p < 0,001$). И что важно — знаки получились логичными:

Рост общего развития (F_1) увеличивает уровень образования на 4,49 процентных пункта.

А структурные перекосы (F_2) и институциональные проблемы (F_3) работают в минус — сдерживают образование на 2,45 и 2,04 пункта соответственно.

Зачем это всё может пригодиться. Мою итоговую робастную модель на главных компонентах с ВМНК можно использовать для прогнозов уровня

образования по доступным экономическим показателям, для поиска приоритетов в политике развития человеческого капитала и для сравнения разных стран между собой.

Что можно сделать дальше. Например, расширить выборку стран, добавить другие институциональные показатели или перейти к панельным данным, чтобы учесть ещё и изменения во времени.

Список литературы

1. Тихомиров Н. П., Тихомирова Т. М. Эконометрика: учебник. — М: Экзамен, 2006. — 512с.
2. Елисеева И.И., Юзбашев М.М. Е51 Общая теория статистики: Учебник / Под ред. И.И. Елисеевой. — 5-е изд., перераб. и доп. — М.: Финансы и статистика, 2004. — 656 с.
3. Магнус Я.Р., Катышев П.К., Персецкий А.А. Эконометрика. Начальный курс: учебник. — 6-е изд. — М: Дело, 2004. — 576 с.
4. Кремер, Н. Ш., Путко, Б. А. Эконометрика: учебник для вузов / Н. Ш. Кремер, Б. А. Путко: под ред. Н. Ш. Кремера. — 2-е изд., перераб. и доп. — Москва: ЮНИТИ-ДАНА, 2020. — 311 с.
5. Новиков, А. И. Эконометрика: учебное пособие / А. И. Новиков. — Москва: ИНФРА-М, 2021. — 256 с.
6. World Bank. Education Statistics (EdStats) [Электронный ресурс]. — Режим доступа: <https://databank.worldbank.org/source/education-statistics> (дата обращения: 15.05.2025).
7. UNESCO Institute for Statistics. Education Indicators [Электронный ресурс]. — Режим доступа: <http://uis.unesco.org/en> (дата обращения: 15.05.2025).
8. United Nations Development Programme. Human Development Reports [Электронный ресурс]. — Режим доступа: <http://hdr.undp.org/en> (дата обращения: 16.05.2025).
9. OECD. Education at a Glance 2024: OECD Indicators [Электронный ресурс]. — Paris: OECD Publishing, 2024. — Режим доступа: <https://www.oecd.org/education/education-at-a-glance/> (дата обращения: 16.05.2025).

10. Росстат. Социально-экономические показатели стран мира: статистический сборник [Электронный ресурс]. — Режим доступа: <https://rosstat.gov.ru/statistics/world> (дата обращения: 17.05.2025).
11. Hanushek, E. A., Woessmann, L. The Knowledge Capital of Nations: Education and the Economics of Growth / E. A. Hanushek, L. Woessmann. — Cambridge, MA: MIT Press, 2020. — 392 p.
12. Barro, R. J., Lee, J. W. Educational Attainment Dataset [Электронный ресурс] / R. J. Barro, J. W. Lee. — 2024. — Режим доступа: <https://www.barrolee.com/> (дата обращения: 17.05.2025).
13. Черемушкин, А. Д. Оценка эффективности тестов гетероскедастичности // Вестник науки. — 2024. — № 1. — URL: <https://cyberleninka.ru/article/n/otsenka-effektivnosti-testov-geteroskedastichnosti> (дата обращения: 18.05.2025).
14. Симоненко, Е. И., Эвтушок, Г. Исследование проблемы автокорреляции в построении эконометричной модели // Форум молодых ученых. — 2023. — № 12 (16). — URL: <https://cyberleninka.ru/article/n/issledovanie-problemy-avtokorelyatsii-v-postroenii-ekonometrichnoy-modeli> (дата обращения: 18.05.2025).
15. World Economic Forum. The Global Competitiveness Report 2024 [Электронный ресурс]. — Geneva: WEF, 2024. — Режим доступа: <https://www.weforum.org/reports/global-competitiveness-report> (дата обращения: 19.05.2025).
16. UNDP. Education Index [Электронный ресурс] // Human Development Data. — 2024. — Режим доступа: <http://hdr.undp.org/en/indicators> (дата обращения: 19.05.2025).
17. Greene, W. H. Econometric Analysis / W. H. Greene. — 8th ed. — New York: Pearson, 2023. — 1104 p.

Приложение 1

Таблица П.1 — Исходные данные для главы 1

У - Уров ень обра зова ния	Х1 - Коэф фици ент Джи ни	Х2 - Оп ыт раб оты (25- 64)	Х3 - Уро вен ь зан ято сти же нщ ин	Х4 - До ля зан ято сти в сел ьск ом хоз яйс тве	Х5 - Гор одс кое насе лен ие%	Х6 - Пра вов ая защ ита	Х7 - Дост уп к фин ансо вым услу гам %	Х8 - Доля жен щин в парл амен те%	Х9 - Расход ы на здраво охране ние(% от ВВП)	Х10 - Досту п к элект ричес тву%	Х11 - Дос туп к вод е и сан итар ии%	Стра на
91,1 5384 62	0,340 0000	61,8 923 077	59,6 538 462	3,03 076 92	86,4 1538 46	90,3 846 154	87,5 0000 00	31,00 0000 0	9,57692 31	99,94 61538	99,9 4615 38	Австр алия
93,6 4615 38	0,300 0000	67,3 846 154	64,8 846 154	3,32 307 69	59,2 7692 31	90,3 846 154	88,0 0000 00	35,92 3076 9	10,6000 000	100,0 00000 0	99,8 6153 85	Австр ия
93,0 0769 23	0,270 0000	63,2 461 538	60,7 769 231	2,12 307 69	98,0 5384 62	90,3 846 154	89,9 2307 69	39,23 8461 5	10,6000 000	100,0 00000 0	99,8 6153 85	Бельг ия
84,6 4615 38	0,533 0769	54,2 230 769	51,4 538 462	9,70 000 00	86,6 9230 77	88,8 461 538	68,4 2307 69	14,61 5384 6	9,59230 77	98,96 15385	96,1 4615 38	Браз илия
93,5 3846 15	0,300 0000	66,7 230 769	64,3 846 154	1,62 307 69	81,5 5384 62	90,3 846 154	91,2 6153 85	29,06 9230 8	11,8692 308	100,0 00000 0	100, 0000 000	Кана да
87,2 4615 38	0,448 4615	50,1 923 077	47,5 000 000	7,80 000 00	86,9 5384 62	90,3 846 154	69,2 3076 92	19,84 6153 8	8,95384 62	99,63 84615	97,7 0000 00	Чили
90,1 7692 31	0,378 4615	58,8 615 385	56,9 692 308	25,8 307 692	57,4 2307 69	65,3 846 154	70,3 8461 54	24,46 9230 8	5,43846 15	98,62 30769	92,4 3076 92	Кита й
87,2 4615 38	0,495 3846	50,1 230 769	48,2 000 000	16,6 384 615	79,9 2307 69	90,3 846 154	64,2 3076 92	18,00 0000 0	7,56153 85	98,06 92308	93,9 7692 31	Колу мбия
87,1 2307 69	0,475 3846	52,1 692 308	50,1 153 846	13,7 615 385	67,6 7692 31	90,3 846 154	63,0 7692 31	25,81 5384 6	8,16923 08	98,81 53846	95,6 0000 00	Коста -Рика
91,1 1538 46	0,300 0000	54,9 769 231	52,4 923 077	5,36 153 85	57,0 6923 08	90,3 846 154	74,8 0769 23	27,19 2307 7	7,07692 31	100,0 00000 0	99,5 6923 08	Хорв атия
89,3 3076 92	0,320 0000	57,2 846 154	54,9 076 923	4,23 846 15	69,8 3846 15	90,3 846 154	84,9 2307 69	21,61 5384 6	7,12307 69	100,0 00000 0	99,5 2307 69	Кипр

93,6 2307 69	0,250 0000	61,5 846 154	59,1 769 231	2,43 846 15	74,2 2307 69	90,3 846 154	79,8 4615 38	21,68 4615 4	7,79230 77	100,0 00000 0	99,8 1538 46	Чехи я
94,7 9230 77	0,280 0000	72,2 923 077	69,4 307 692	2,55 384 62	88,2 3846 15	90,3 846 154	94,1 9230 77	40,88 4615 4	11,3846 154	100,0 00000 0	100, 0000 000	Дани я
93,7 4615 38	0,340 0000	64,2 538 462	61,7 923 077	6,27 692 31	69,4 0769 23	90,3 846 154	85,2 3076 92	25,17 6923 1	7,12307 69	100,0 00000 0	99,4 3846 15	Эстон ия
94,9 2307 69	0,270 0000	67,8 000 000	65,0 384 615	2,75 384 62	85,2 9230 77	90,3 846 154	92,1 9230 77	45,23 0769 2	10,7692 308	100,0 00000 0	100, 0000 000	Финл янди я
94,3 6153 85	0,300 0000	63,0 307 692	60,7 538 462	3,11 538 46	81,1 0769 23	90,3 846 154	91,0 7692 31	37,96 9230 8	11,7692 308	100,0 00000 0	99,8 6153 85	Фран ция
94,2 6923 08	0,290 0000	71,2 153 846	68,0 692 308	1,36 923 08	75,0 2307 69	90,3 846 154	91,4 6153 85	34,30 0000 0	12,2461 538	100,0 00000 0	99,8 6153 85	Герм ания
90,4 5384 62	0,330 0000	52,3 076 923	49,7 538 462	11,5 769 231	79,2 3846 15	90,3 846 154	69,8 4615 38	23,84 6153 8	7,28461 54	100,0 00000 0	99,5 7692 31	Грец ия
92,6 1538 46	0,300 0000	56,9 307 692	54,5 384 615	4,56 923 08	71,2 9230 77	90,3 846 154	74,9 2307 69	21,61 5384 6	6,88461 54	100,0 00000 0	99,4 7692 31	Венгр ия
63,3 2307 69	0,350 0000	47,7 000 000	51,4 769 231	43,4 384 615	33,4 3076 92	63,5 384 615	56,2 2307 69	13,63 8461 5	3,38461 54	97,48 46154	83,9 0000 00	Инди я
79,3 0769 23	0,383 0769	51,1 769 231	49,2 538 462	31,1 692 308	57,0 6153 85	65,3 846 154	51,1 1538 46	20,52 3076 9	3,60000 00	97,00 00000	88,1 9230 77	Индо незия
93,7 4615 38	0,330 0000	63,1 153 846	60,7 076 923	5,20 000 00	63,2 3846 15	90,3 846 154	89,6 9230 77	28,73 0769 2	8,24615 38	100,0 00000 0	99,8 1538 46	Ирла ндия
92,1 1538 46	0,390 0000	59,2 153 846	56,9 230 769	1,58 461 54	92,6 3846 15	65,3 846 154	71,6 1538 46	27,05 3846 2	8,06153 85	100,0 00000 0	99,7 5384 62	Изра иль
91,4 6153 85	0,340 0000	53,6 538 462	50,9 076 923	4,07 692 31	70,6 7692 31	90,3 846 154	76,3 8461 54	27,07 6923 1	9,69230 77	100,0 00000 0	99,7 8461 54	Итал ия
96,6 1538 46	0,330 0000	52,2 538 462	49,9 615 385	3,88 461 54	91,8 9230 77	65,3 846 154	76,0 0000 00	10,03 8461 5	10,4538 462	100,0 00000 0	99,8 6153 85	Япон ия
94,1 7692 31	0,270 0000	61,4 000 000	58,9 384 615	2,16 153 85	61,4 0769 23	65,3 846 154	64,8 4615 38	23,69 2307 7	4,06153 85	99,75 38462	98,6 0000 00	Казах стан
93,1 1538 46	0,350 0000	60,1 153 846	57,6 153 846	6,77 692 31	68,1 6923 08	90,3 846 154	81,0 0000 00	25,17 6923 1	7,12307 69	100,0 00000 0	99,4 3846 15	Латв ия
93,7 4615 38	0,360 0000	61,1 153 846	58,6 153 846	7,63 846 15	68,1 1538 46	90,3 846 154	81,0 0000 00	21,61 5384 6	7,10769 23	100,0 00000 0	99,2 7692 31	Литв а

90,1 1538 46	0,310 0000	60,1 153 846	57,6 153 846	1,11 538 46	91,4 0769 23	90,3 846 154	93,8 4615 38	29,34 6153 8	7,26923 08	100,0 00000 0	100, 0000 000	Люкс ембу рг
84,6 1538 46	0,412 3077	54,3 230 769	52,5 384 615	11,8 230 769	76,8 0769 23	65,3 846 154	84,8 4615 38	12,50 0000 0	4,14615 38	99,63 84615	96,8 7692 31	Мала йзия
82,0 6153 85	0,454 6154	50,2 076 923	48,4 923 077	13,9 615 385	79,8 6923 08	84,2 307 692	64,8 4615 38	23,19 2307 7	6,21538 46	99,16 15385	96,0 3076 92	Мекс ика
64,6 1538 46	0,393 0769	22,1 153 846	20,7 538 462	31,4 846 154	63,4 0769 23	50,0 000 000	44,8 4615 38	22,84 6153 8	5,88461 54	93,80 76923	85,5 3846 15	Маро кко
94,5 3846 15	0,280 0000	65,5 384 615	63,1 692 308	2,11 538 46	92,2 3846 15	90,3 846 154	94,1 9230 77	35,88 4615 4	11,8846 154	100,0 00000 0	100, 0000 000	Ниде рлан ды
93,1 1538 46	0,330 0000	64,1 153 846	61,7 538 462	6,91 538 46	83,9 6153 85	90,3 846 154	92,6 1538 46	46,54 6153 8	10,7692 308	100,0 00000 0	100, 0000 000	Нова я Зела ндия
52,2 6923 08	0,360 0000	45,8 846 154	49,4 615 385	39,6 769 231	51,4 0769 23	59,2 307 692	41,9 2307 69	8,230 7692	3,00000 00	78,10 76923	67,7 1538 46	Ниге рия
95,0 8461 54	0,270 0000	73,3 461 538	70,5 846 154	2,43 846 15	83,2 2307 69	90,3 846 154	97,0 0000 00	43,84 6153 8	11,2307 692	100,0 00000 0	100, 0000 000	Норв егия
46,4 0384 62	0,300 0000	22,5 730 769	21,0 538 462	36,4 076 923	37,8 9615 38	50,0 000 000	24,9 4230 77	22,96 5384 6	3,23076 92	93,26 92308	71,9 2307 69	Паки стан
85,0 0000 00	0,441 5385	53,3 076 923	51,3 076 923	6,22 307 69	79,0 3076 92	90,3 846 154	67,8 4615 38	28,84 6153 8	7,30000 00	98,38 46154	92,3 0769 23	Перу
88,0 0000 00	0,401 5385	47,4 615 385	44,7 384 615	25,2 461 538	46,6 1538 46	65,3 846 154	57,7 6923 08	27,50 0000 0	4,28461 54	97,00 00000	90,5 0000 00	Фили ппин ы
93,4 1538 46	0,310 0000	59,0 000 000	56,5 153 846	6,12 307 69	60,1 6923 08	90,3 846 154	81,0 0000 00	21,61 5384 6	6,99230 77	100,0 00000 0	99,6 0000 00	Поль ша
89,7 0769 23	0,330 0000	59,5 000 000	57,3 076 923	5,20 769 23	66,7 3076 92	90,3 846 154	86,0 0000 00	36,38 4615 4	10,6000 000	100,0 00000 0	99,8 1538 46	Порт угали я
91,0 0000 00	0,330 0000	54,7 076 923	52,7 076 923	25,5 000 000	54,1 2307 69	90,3 846 154	72,0 0000 00	21,00 0000 0	5,93076 92	99,76 92308	98,3 0769 23	Румы ния
94,6 1538 46	0,380 0000	61,6 153 846	59,6 769 231	5,57 692 31	74,9 3076 92	65,3 846 154	81,0 0000 00	15,83 0769 2	5,25384 62	99,76 92308	98,7 6923 08	Росси йская Феде раци я
86,0 0000 00	0,342 3077	22,9 230 769	20,7 846 154	1,20 000 00	84,9 9230 77	50,0 000 000	42,0 0000 00	8,000 0000 0000	5,20000 00	100,0 00000 0	99,2 1538 46	Сауд овска я Арав ия

92,0 0000 00	0,371 5385	54,5 000 000	52,5 000 000	15,8 230 769	56,7 9230 77	65,3 846 154	72,0 0000 00	26,00 0000 0	6,93076 92	98,38 46154	97,5 0000 00	Серб ия
95,6 1538 46	0,382 3077	64,6 153 846	62,1 153 846	0,11 538 46	100, 0000 000	65,3 846 154	91,0 0000 00	28,23 0769 2	4,76923 08	100,0 00000 0	100, 0000 000	Синга пур
93,7 4615 38	0,250 0000	60,7 461 538	58,2 538 462	3,22 307 69	53,6 0000 00	90,3 846 154	81,0 0000 00	21,61 5384 6	7,76923 08	100,0 00000 0	99,6 0769 23	Слов акия
94,2 5384 62	0,250 0000	62,7 461 538	60,2 538 462	4,22 307 69	56,2 2307 69	90,3 846 154	91,0 0000 00	33,84 6153 8	8,43076 92	100,0 00000 0	99,8 1538 46	Слов ения
85,0 0000 00	0,630 0000	45,0 000 000	42,5 769 231	4,58 461 54	66,4 6923 08	75,0 000 000	58,8 4615 38	48,00 0000 0	8,93076 92	96,00 00000	93,0 0000 00	Южн о- Афри канск ая Респу блик а
98,8 7692 31	0,352 3077	58,0 000 000	54,4 538 462	5,07 692 31	82,0 0000 00	83,0 000 000	86,0 0000 00	19,00 7692 3	8,12307 69	100,0 00000 0	99,6 1538 46	Южн ая Коре я
92,3 0769 23	0,341 5385	58,3 076 923	56,3 076 923	4,20 769 23	80,6 5384 62	90,3 846 154	91,0 0000 00	38,84 6153 8	10,6846 154	100,0 00000 0	99,8 1538 46	Испа ния
95,7 4615 38	0,290 0000	73,7 461 538	71,2 538 462	1,82 307 69	87,5 3846 15	90,3 846 154	97,0 0000 00	49,00 0000 0	11,7000 000	100,0 00000 0	100, 0000 000	Швец ия
93,9 3846 15	0,330 0000	64,9 384 615	62,4 538 462	2,33 076 92	74,1 0769 23	90,3 846 154	95,0 0000 00	36,00 0000 0	13,2000 000	100,0 00000 0	100, 0000 000	Швей цари я
90,0 0000 00	0,352 3077	59,6 153 846	57,7 384 615	31,2 076 923	37,4 9230 77	65,3 846 154	81,0 0000 00	21,00 0000 0	4,48461 54	99,26 92308	96,0 0000 00	Таил анд
75,0 0000 00	0,321 5385	24,6 153 846	24,2 461 538	15,8 230 769	67,7 3076 92	65,3 846 154	52,0 0000 00	32,00 0000 0	7,62307 69	98,61 53846	95,0 0000 00	Тунис
80,7 1538 46	0,413 0769	36,3 076 923	34,8 076 923	19,5 076 923	75,8 3846 15	65,3 846 154	62,0 0000 00	17,80 7692 3	5,88461 54	99,76 92308	99,2 6153 85	Турц ия
91,6 1538 46	0,260 0000	57,6 153 846	55,6 153 846	14,4 000 000	69,2 3846 15	65,3 846 154	72,0 0000 00	19,84 6153 8	7,44615 38	99,76 92308	98,8 4615 38	Укра ина
89,6 1538 46	0,261 5385	54,2 307 692	52,4 230 769	0,43 846 15	86,6 1538 46	50,0 000 000	77,0 0000 00	26,00 0000 0	4,79230 77	100,0 00000 0	99,6 3846 15	Обье динё нные Араб ские Эмир аты

94,5 0000 00	0,350 0000	65,3 076 923	63,0 692 308	1,02 307 69	84,3 6923 08	90,3 846 154	95,0 0000 00	29,46 1538 5	10,9000 000	100,0 00000 0	100, 0000 000	Соед инён ное Коро левст во
93,5 0000 00	0,410 0000	66,3 076 923	64,0 769 231	1,42 307 69	82,9 3846 15	90,3 846 154	93,0 0000 00	24,00 0000 0	18,2000 000	100,0 00000 0	99,9 0000 00	Соед инён ные Штат ы Амер ики
90,5 0000 00	0,390 0000	56,5 000 000	54,5 000 000	6,20 769 23	95,1 0769 23	90,3 846 154	72,0 0000 00	19,69 2307 7	9,66153 85	99,88 46154	97,5 0000 00	Уругв ай
88,0 0000 00	0,360 0000	54,6 153 846	52,6 153 846	35,5 000 000	37,0 0000 00	65,3 846 154	72,0 0000 00	31,00 0000 0	7,20000 00	99,26 92308	95,0 0000 00	Вьетн ам
87,2 4615 38	0,340 0000	50,1 230 769	48,2 000 000	13,5 923 077	93,1 5384 62	90,3 846 154	55,7 6923 08	37,88 4615 4	9,15384 62	96,15 38462	95,2 0000 00	Арге нтина
60,7 6923 08	0,320 0000	27,1 230 769	25,5 923 077	40,5 000 000	33,7 6923 08	50,0 000 000	25,7 6923 08	22,88 4615 4	3,07692 31	90,76 92308	75,0 0000 00	Бангл адеш
75,7 6923 08	0,320 0000	24,1 230 769	22,5 923 077	23,5 000 000	48,7 6923 08	50,0 000 000	40,7 6923 08	17,88 4615 4	6,15384 62	97,88 46154	95,0 0000 00	Египе т
80,7 6923 08	0,420 0000	37,1 230 769	35,5 923 077	65,5 000 000	30,7 6923 08	50,0 000 000	35,7 6923 08	22,88 4615 4	5,15384 62	85,76 92308	70,0 0000 00	Кени я
46,4 0384 62	0,300 0000	22,5 730 769	21,0 538 462	36,4 076 923	37,8 9615 38	50,0 000 000	24,9 4230 77	22,96 5384 6	3,23076 92	93,26 92308	75,0 0000 00	Паки стан
87,2 4615 38	0,440 0000	47,1 230 769	45,5 923 077	7,63 846 15	89,1 5384 62	90,3 846 154	55,7 6923 08	27,88 4615 4	9,15384 62	91,15 38462	93,2 0000 00	Вене суэла
75,7 6923 08	0,350 0000	37,1 230 769	35,5 923 077	17,1 153 846	57,8 8461 54	50,0 000 000	45,7 6923 08	32,88 4615 4	7,15384 62	92,88 46154	90,0 0000 00	Алжи р
66,0 7142 86	0,580 0000	37,2 000 000	35,6 571 429	55,3 214 286	41,0 7142 86	50,0 000 000	31,0 7142 86	18,03 5714 3	4,10714 29	88,03 57143	75,0 0000 00	Анго ла

Приложение 2

Таблица П.2 — Матрица парных коэффициентов корреляции (70 стран)

Матрица парных корреляций W											
	X - Коэффициент Джини	X1 - Опыт работы(25-64)	X2 - Уровень занятости в сельском хозяйстве	X3 - Доля занятости в сельском хозяйстве	X4 - Городское население%	X5 - Правовая защита	X6 - Доступ к финансовым услугам%	X7 - Доля женщин в парламенте%	X8 - Расходы на здравоохранение(% от ВВП)	X9 - Доступ к электричеству%	X10 - Доступ к воде и санитарии%
X - Коэффициент Джини	1	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561
X1 - Опыт работы(25-64)	0,290101561	1	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561
X2 - Уровень занятости в сельском хозяйстве	0,290101561	0,290101561	1	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561
X3 - Доля занятости в сельском хозяйстве	0,290101561	0,290101561	0,290101561	1	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561
X4 - Городское население%	0,290101561	0,290101561	0,290101561	0,290101561	1	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561
X5 - Правовая защита	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	1	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561
X6 - Доступ к финансовым услугам%	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	1	0,290101561	0,290101561	0,290101561	0,290101561
X7 - Доля женщин в парламенте%	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	1	0,290101561	0,290101561	0,290101561
X8 - Расходы на здравоохранение(% от ВВП)	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	1	0,290101561	0,290101561
X9 - Доступ к электричеству%	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	1	0,290101561
X10 - Доступ к воде и санитарии%	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	0,290101561	1

Таблица П.4 — Диагностика мультиколлинеарности: коэффициенты детерминации и VIF

Наименование фактора	R 0	R Xj	альфа j	VIF j
X1 - Коэффициент Джини	-0,20087069	0,290101561	4,668101653	1,408652203
X2 - Опыт работы(25-64)	0,793228803	0,996084562	3,108022631	255,3992442
X3 - Уровень занятости женщин	0,761279176	0,99588542	-2,699017852	243,0381549
X4 - Доля занятости в сельском хозяйстве	-0,738652263	0,857007098	0,215309887	6,993354114
X5 - Городское население%	0,575774389	0,679054474	0,004639413	3,115793554
X6 - Правовая защита	0,650746054	0,658802269	-0,04598689	2,930851848
X7 - Доступ к финансовым услугам%	0,83614994	0,926621195	-0,045157857	13,62791341
X8 - Доля женщин в парламенте%	0,336120816	0,403207508	-0,060404856	1,675624297
X9 - Расходы на здравоохранение(% от ВВП)	0,580955946	0,649626088	0,061526332	2,854093776
X10 - Доступ к электричеству%	0,725589989	0,84365667	-1,110793229	6,396179479
X11 - Доступ к воде и санитарии%	0,881344413	0,922115001	1,587844207	12,83944301